



UNIVERSIDAD
CATÓLICA DE
TEMUCO

DEPARTAMENTO DE
INGENIERÍA INFORMÁTICA
FACULTAD DE INGENIERÍA

**Sistema ANFIS para Detección Automática de Tumores Cerebrales en
Imágenes de Resonancia Magnética**

por

José Miguel Alderete López

Trabajo de Título presentado a la
Facultad de Ingeniería de la Universidad Católica de Temuco
Para Optar al Título de Ingeniero Civil Informático.

- Temuco, Noviembre 2025 -



COMISIÓN EXAMEN DE TÍTULO

Este Examen de Título ha sido realizado en la Escuela de Ingeniería Informática:

Presidente Comisión:

.....
Prof. Mario Augusto Villanueva
Magister en Gestión de Tecnologías de la
Información
Ingeniero Informático
Jefe Carrera Ing. Civil Informática

Profesor Guía:

.....
Prof. Marcos Lévano Huamaccto
Magíster en Ingeniería en Informática
Ingeniero Informático

Profesor Informante:

.....
Prof. Luis Alberto Caro
Ingeniero civil Informático

Jefe Carrera de Ingeniería
Civil Informática:

.....
Sr. Mario Augusto Villanueva
Magister en Gestión de Tecnologías de la
Información
Ingeniero Informático
Jefe Carrera Ing. Civil Informática

Temuco, 28 de [] de 2025.

AGRADECIMIENTOS

Agradezco profundamente a mis padres, hermana, familia, amigos y pareja por su apoyo constante e incondicional. En especial a mis padres, cuyo respaldo ha sido fundamental para alcanzar mis objetivos y llegar a este momento. Extiendo también mi gratitud a mis docentes por su orientación, dedicación y motivación a lo largo de este proceso.

Índice general

Índice general	I
Índice de figuras	III
Índice de cuadros	IV
Resumen	V
Abstract	VI
1 Introducción	1
1.1. Definición del Problema	1
1.2. Estado del Arte	2
1.3. Objetivos	4
2 Marco Teórico	5
2.1. Sistemas Neuro-Difusos Adaptativos (ANFIS)	5
2.2. Matrices de Co-ocurrencia de Niveles de Gris (GLCM) . . .	6
2.3. Optimización por Enjambre de Partículas (PSO)	7
2.4. Entrenamiento Híbrido Basado en PSO y Mínimos Cua- drados	7
3 Diseño e Implementación	9
3.1. Diseño del Sistema	9
3.2. Interfaz Gráfica de Usuario	29
4 Resultados y Análisis	34
4.1. Implementación Técnica	34
4.2. Evaluación del Modelo ANFIS	35

<i>ÍNDICE GENERAL</i>	II
4.3. Análisis de Características GLCM	37
4.4. Análisis de Reglas ANFIS	39
4.5. Interpretación Clínica Basada en Evidencia	41
4.6. Conclusiones del Análisis	44
5 Conclusiones	45
Bibliografía	48
Appendices	50
Anexos	51
A Anexo Técnico – Códigos Fuente	51
A.1. Repositorio Completo	51
A.2. Análisis Reglas.txt	51

Índice de figuras

3.1.	Esquema del proceso que seguirá el entrenamiento del modelo	10
3.2.	Diagrama detallado del pipeline de preprocesamiento de imágenes MRI	12
3.3.	Resultados intermedios del pipeline de preprocesamiento. (a) Imagen MRI original. (b) Mejora de contraste mediante CLAHE. (c) Reducción de ruido con filtro bilateral. (d) Máscara binaria generada por segmentación adaptativa. (e) Región de interés (ROI) final recortada.	16
3.4.	Arquitectura detallada del modelo ANFIS implementado . . .	17
3.5.	Diagrama del proceso de entrenamiento híbrido PSO-LSE . . .	25
3.6.	Interfaz general del sistema ANFIS para detección de tumores cerebrales	30
3.7.	Módulo de gestión y visualización de datos	30
3.8.	Panel de control para ejecución del entrenamiento	31
3.9.	Panel de herramientas adicionales del sistema	31
3.10.	Interfaz del Visualizador de resultados y reglas	32
3.11.	Interfaz del Configurador de parámetros ANFIS	33
4.1.	Evaluación completa del modelo ANFIS que incluye matriz de confusión, curva ROC y métricas de rendimiento detalladas	36
4.2.	Importancia relativa de las características GLCM en el modelo ANFIS, calculada a partir del impacto acumulado de todas las reglas	38
4.3.	Distribución de importancia entre las 128 reglas ANFIS generadas por el modelo, mostrando el dominio de un subconjunto pequeño de reglas	40
4.4.	Mapa de calor mostrando patrones de activación en las reglas más importantes del sistema ANFIS, organizadas por similitud de comportamiento	41

Índice de cuadros

4.1. Tecnologías para el Desarrollo de la Interfaz	34
4.2. Especificaciones de hardware y software utilizadas en el desarrollo	35

Resumen

Este trabajo presenta el desarrollo e implementación de un sistema ANFIS (Adaptive Neuro-Fuzzy Inference System) para la detección automática de tumores cerebrales en imágenes de resonancia magnética. El sistema utiliza características texturales extraídas mediante matrices de co-ocurrencia de niveles de gris (GLCM) y se optimiza mediante un enfoque híbrido basado en Optimización por Enjambre de Partículas (PSO) y Mínimos Cuadrados (LSE).

Los datos utilizados fueron obtenidos desde un conjunto público disponible en Kaggle, compuesto por más de 3000 imágenes MRI etiquetadas, empleadas para las etapas de entrenamiento, validación y prueba del modelo.

Se implementó un modelo ANFIS de tipo Sugeno con 7 características GLCM como entradas, 128 reglas difusas y una arquitectura de cinco capas. Además, se desarrolló una interfaz gráfica en Python que integra todo el flujo del sistema: preprocesamiento, extracción de características, entrenamiento, clasificación y visualización de resultados.

Los experimentos realizados muestran un rendimiento sobresaliente, alcanzando una precisión del 96.43 %, una sensibilidad del 88.24 %, una especificidad del 97.53 % y un área bajo la curva ROC del 96.43 %. El sistema fue empaquetado como un ejecutable portable, lo que demuestra su viabilidad para pruebas y uso en entornos no especializados.

En conjunto, los resultados evidencian que los modelos ANFIS constituyen una alternativa efectiva y altamente interpretable para tareas de clasificación en imágenes médicas MRI, combinando desempeño competitivo con una estructura transparente y accesible.

Palabras clave: ANFIS, GLCM, PSO, Tumores Cerebrales, MRI, Sistema Neuro-Difuso, Clasificación de Imágenes Médicas.

Resumen

This work presents the development and implementation of an ANFIS (Adaptive Neuro-Fuzzy Inference System) for the automatic detection of brain tumors in magnetic resonance imaging (MRI). The system uses textural features extracted through Gray-Level Co-occurrence Matrices (GLCM) and is optimized using a hybrid approach that combines Particle Swarm Optimization (PSO) and Least Squares Estimation (LSE).

The dataset employed was obtained from a publicly available collection on Kaggle, consisting of more than 3000 labeled MRI images used for training, validation, and testing of the model.

A Sugeno-type ANFIS model was implemented with 7 GLCM features as inputs, 128 fuzzy rules, and a five-layer architecture. Additionally, a graphical user interface (GUI) was developed in Python, integrating the entire system workflow: image preprocessing, feature extraction, model training, classification, and result visualization.

The experimental results show outstanding performance, achieving an accuracy of 96.43 %, a sensitivity of 88.24 %, a specificity of 97.53 %, and an area under the ROC curve (AUC) of 96.43 %. The system was packaged as a portable executable, demonstrating its feasibility for testing and use in non-specialized environments.

Overall, the findings indicate that ANFIS-based models represent an effective and highly interpretable alternative for MRI-based medical image classification tasks, combining competitive performance with transparency and accessibility.

Keywords: ANFIS, GLCM, PSO, Brain Tumors, MRI, Neuro-Fuzzy Systems, Medical Image Classification.

Capítulo 1

Introducción

1.1. Definición del Problema

Descripción

Los tumores cerebrales representan una de las patologías más complejas dentro de la neurología y la neurocirugía, debido a su elevada morbilidad y a la dificultad asociada a su diagnóstico preciso. Aunque solo constituyen aproximadamente el 2 % de todos los cánceres a nivel global, su impacto clínico es considerablemente mayor [11].

La resonancia magnética (MRI) es la técnica principal para su evaluación, ya que proporciona imágenes anatómicas detalladas de alta resolución [9]. Sin embargo, su interpretación depende fuertemente de la experiencia del especialista y está sujeta a variabilidad, fatiga y subjetividad. Dentro de estos tumores, los meningiomas destacan por su alta frecuencia y su variabilidad histológica [8, 10]. La automatización en la detección de estas lesiones puede apoyar el trabajo clínico mediante la identificación temprana de patrones sospechosos.

El presente trabajo propone un sistema de apoyo al diagnóstico basado en un modelo ANFIS (Adaptive-Network-based Fuzzy Inference System), entrenado con características texturales extraídas mediante matrices de co-ocurrencia de niveles de gris (GLCM), una técnica ampliamente utilizada en imágenes médicas para la representación de patrones texturales relevantes.

Justificación

La detección temprana de tumores cerebrales mejora significativamente el pronóstico clínico, permitiendo intervenciones más oportunas. No obstante, el análisis manual de imágenes MRI presenta desafíos como la variabilidad interobservador, la complejidad visual de los patrones tumorales y la carga laboral sostenida en entornos hospitalarios. En este contexto, los sistemas automáticos resultan fundamentales para apoyar la toma de decisiones clínicas.

GLCM es una técnica sólida y ampliamente estudiada para la extracción de características texturales en imágenes médicas [3]. Por su parte, ANFIS combina lógica difusa y redes neuronales, lo que permite construir modelos explicables capaces de manejar incertidumbre y aprender a partir de datos [6]. Estudios recientes han demostrado la utilidad de ANFIS tanto en diagnósticos basados en imágenes de tumores cerebrales [1] como en otras patologías [2].

Si bien inicialmente se contemplaba una comparativa entre algoritmos, optamos por usar exclusivamente particle swarm optimization [12], por lo cual el proyecto se centró finalmente en la construcción de una interfaz gráfica de usuario y una versión portable del sistema, buscando maximizar la usabilidad y el impacto práctico del software. A diferencia de numerosos trabajos desarrollados en MATLAB, esta propuesta utiliza Python, favoreciendo la accesibilidad, la reproducibilidad y la portabilidad.

1.2. Estado del Arte

La detección automática de tumores cerebrales mediante herramientas computacionales se apoya en tres pilares metodológicos: la teoría de los conjuntos difusos, la extracción de características texturales en imágenes médicas y los sistemas neuro-difusos adaptativos. A continuación se describen los trabajos fundacionales y las investigaciones recientes más relevantes para este proyecto.

Trabajos Fundacionales

Lógica Difusa

Zadeh y colaboradores introdujeron los conjuntos difusos como un marco matemático para representar incertidumbre y gradualidad en sistemas de decisión [4]. Sus aportes constituyen la base de los sistemas de inferencia difusa utilizados en distintas áreas de la inteligencia computacional. A pesar de su relevancia, la teoría original no incorpora mecanismos de aprendizaje automático, limitación que motiva la adopción de modelos neuro-difusos como ANFIS en el presente proyecto.

GLCM para Análisis de Textura

Haralick et al. desarrollaron la matriz de co-ocurrencia de niveles de gris como una técnica para cuantificar patrones de textura mediante relaciones espaciales entre píxeles [5]. Esta propuesta introdujo descriptores como contraste, homogeneidad, energía y entropía.

ANFIS: Sistemas Neuro-Difusos

Jang introdujo ANFIS como un modelo híbrido capaz de ajustar parámetros difusos mediante técnicas de aprendizaje propias de redes neuronales [6]. Su investigación evidenció resultados positivos en problemas de clasificación y regresión, aunque sin aplicación directa al análisis de imágenes médicas.

Investigaciones Recientes

ANFIS aplicado a tumores cerebrales

Sharma et al. propusieron un sistema ANFIS con características GLCM para clasificación de tumores cerebrales en imágenes de resonancia magnética, reportando una precisión del 98.67 % [1]. Sin embargo, su metodología depende de una etapa de preprocesamiento que incluye operaciones morfológicas y binarización, lo que añade complejidad computacional.

ANFIS en diagnóstico médico general

Al-ali et al. aplicaron ANFIS con GLCM para la detección automática de COVID-19 en imágenes de rayos X, logrando una precisión del 98.67 % [2]. Este trabajo validó la aplicabilidad clínica del enfoque neuro-difuso en imágenes médicas, incluso con conjuntos de datos limitados. Nuestra investigación traslada este paradigma al diagnóstico de meningiomas mediante MRI, un dominio donde la interpretabilidad y la facilidad de uso son críticas.

GLCM en imágenes médicas

Mohanaiah et al. realizaron una implementación eficiente de características GLCM en hardware, destacando su utilidad en aplicaciones de tiempo real [3]. Concluyeron que descriptores como energía, entropía y contraste presentan alto poder discriminativo. En este proyecto, utilizamos un subconjunto de estas características como entrada a ANFIS, optimizando el balance entre precisión y eficiencia.

1.3. Objetivos

Objetivo general

Desarrollar un sistema ANFIS con interfaz gráfica para la detección automática de tumores cerebrales en imágenes de resonancia magnética mediante características GLCM.

Objetivos específicos

- Implementar un modelo ANFIS optimizado con PSO para clasificación de tumores cerebrales basado en características texturales GLCM.
- Diseñar una interfaz gráfica de usuario intuitiva y portable que facilite la interacción con el sistema de diagnóstico.
- Evaluar el desempeño del sistema mediante métricas de clasificación y analizar la interpretabilidad de las reglas difusas generadas.

Capítulo 2

Marco Teórico

2.1. Sistemas Neuro-Difusos Adaptativos (ANFIS)

Los Sistemas Neuro-Difusos Adaptativos (ANFIS, por sus siglas en inglés *Adaptive Neuro-Fuzzy Inference System*) representan una fusión entre la lógica difusa y las redes neuronales artificiales. Desarrollado por Jang [6], ANFIS combina la capacidad de los sistemas difusos para manejar conocimiento impreciso con la capacidad de aprendizaje de las redes neuronales.

Arquitectura ANFIS Tipo Sugeno

La arquitectura ANFIS implementada en este trabajo sigue el modelo de Sugeno de primer orden, que consta de cinco capas:

- **Capa 1 (Fuzzificación):** Transforma las variables de entrada en grados de pertenencia mediante funciones de membresía.
- **Capa 2 (Evaluación de Reglas):** Calcula el firing strength de cada regla difusa.
- **Capa 3 (Normalización):** Normaliza los firing strengths.
- **Capa 4 (Consecuentes):** Calcula la salida de cada regla.
- **Capa 5 (Agregación):** Combina las salidas de todas las reglas.

La función de membresía gaussiana utilizada está definida por:

$$\mu_{ij}(x_i) = \exp \left(-\frac{1}{2} \left(\frac{x_i - c_{ij}}{\sigma_{ij}} \right)^2 \right) \quad (2.1)$$

donde c_{ij} y σ_{ij} representan el centro y ancho de la función gaussiana para la característica i y conjunto j .

2.2. Matrices de Co-ocurrencia de Niveles de Gris (GLCM)

Las Matrices de Co-ocurrencia de Niveles de Gris, introducidas por Haralick et al. [5], son una técnica fundamental para el análisis de textura en imágenes. Una GLCM $P(i, j)$ representa la frecuencia con la que un píxel con intensidad i aparece en una relación espacial específica con un píxel de intensidad j .

Las características texturales extraídas incluyen:

Momento Angular Segundo (ASM)

$$ASM = \sum_{i=1}^N \sum_{j=1}^N [P(i, j)]^2 \quad (2.2)$$

Contraste

$$Contraste = \sum_{i=1}^N \sum_{j=1}^N (i - j)^2 P(i, j) \quad (2.3)$$

Energía

$$Energía = \sqrt{ASM} \quad (2.4)$$

Homogeneidad

$$Homogeneidad = \sum_{i=1}^N \sum_{j=1}^N \frac{P(i, j)}{1 + |i - j|} \quad (2.5)$$

Entropía

$$Entropa = - \sum_{i=1}^N \sum_{j=1}^N P(i, j) \log(P(i, j)) \quad (2.6)$$

2.3. Optimización por Enjambre de Partículas (PSO)

El algoritmo de Optimización por Enjambre de Partículas, desarrollado por Kennedy y Eberhart [12], es un método de optimización basado en población que simula el comportamiento social de bandadas de pájaros o cardúmenes de peces.

Cada partícula i en el enjambre tiene una posición $\vec{x}_i$ y velocidad $\vec{v}_i$ que se actualizan en cada iteración:

$$\vec{v}_i^{t+1} = \omega \vec{v}_i^t + c_1 r_1 (\vec{p}_{best,i} - \vec{x}_i^t) + c_2 r_2 (\vec{g}_{best} - \vec{x}_i^t) \quad (2.7)$$

$$\vec{x}_i^{t+1} = \vec{x}_i^t + \vec{v}_i^{t+1} \quad (2.8)$$

donde ω es el factor de inercia, c_1 y c_2 son coeficientes de aceleración, r_1 y r_2 son números aleatorios, $\vec{p}_{best,i}$ es la mejor posición personal de la partícula i , y $\vec{g}_{best}$ es la mejor posición global del enjambre.

2.4. Entrenamiento Híbrido Basado en PSO y Mínimos Cuadrados

El entrenamiento híbrido implementado combina el algoritmo PSO para optimizar los parámetros no lineales de las funciones de membresía (centros y anchos) y el método de Mínimos Cuadrados (LSE) para

estimar los parámetros lineales de los consecuentes del modelo de Sugeno. Este enfoque mantiene la estructura de aprendizaje propuesta originalmente por Jang [6], pero reemplaza el descenso del gradiente por un método evolutivo, tal como ha sido explorado en diversas variantes modernas de ANFIS.

Para un conjunto de entrenamiento de N muestras y un sistema con R reglas y d características de entrada, la matriz de diseño F se define como:

$$F = \begin{bmatrix} \bar{w}_1^{(1)} x_1^{(1)} & \cdots & \bar{w}_1^{(1)} x_d^{(1)} & \bar{w}_1^{(1)} & \cdots & \bar{w}_R^{(1)} x_1^{(1)} & \cdots & \bar{w}_R^{(1)} x_d^{(1)} & \bar{w}_R^{(1)} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ \bar{w}_1^{(N)} x_1^{(N)} & \cdots & \bar{w}_1^{(N)} x_d^{(N)} & \bar{w}_1^{(N)} & \cdots & \bar{w}_R^{(N)} x_1^{(N)} & \cdots & \bar{w}_R^{(N)} x_d^{(N)} & \bar{w}_R^{(N)} \end{bmatrix} \quad (2.9)$$

donde $\bar{w}_k^{(n)}$ es el grado de activación normalizado de la regla k para la muestra n .

Los parámetros lineales de los consecuentes se obtienen resolviendo:

$$\theta = (F^T F)^{-1} F^T y \quad (2.10)$$

Este enfoque híbrido se beneficia de la capacidad de PSO para explorar de manera global el espacio de parámetros no lineales y de la eficiencia computacional del método de Mínimos Cuadrados para los parámetros lineales.

Capítulo 3

Diseño e Implementación

3.1. Diseño del Sistema

Se plantea un esquema donde la primera parte de recorrido consiste en la obtención de las imágenes, su procesamiento, obtención de características GLCM, normalizamos los datos y entramos con el proceso de entrenamiento de ANFIS, donde se debe inicializar parámetros, límites de búsqueda, objetivos MSE, y se optimiza con LSE dándonos un modelo entrenado listo para su evaluación, para mas referencia guiarse por la Figura 3.1.




Figura 3.1: Esquema del proceso que seguirá el entrenamiento del modelo

Imágenes

Las imágenes provienen de una base de datos en Kaggle [7], de la cual se tiene resonancias magneticas de distintos tipos cerebros con y sin tumores, donde se tiene meningiomas, pituitarias y gliomas, ademas de MRI de cerebros sanos.

Para el trabajo presente se usaron MRI de cerebros con meningiomas y sanos, donde la totalidad de imágenes son de 2914, de las cuales 1339 son pertenecientes a meningiomas y las 1575 sobrantes a MRI sanos. Para la pruebas de testeo se usan 691 muestras, donde 306 son meningiomas y las restantes sanos.

Procesamiento de imágenes

El preprocesamiento de las imágenes MRI es una etapa crítica para garantizar la calidad de las características extraídas y el rendimiento del modelo ANFIS. El proceso completo, ilustrado en la Figura 3.2, sigue un pipeline sistemático que incluye mejora de contraste, filtrado, segmentación y extracción de regiones de interés.




Figura 3.2: Diagrama detallado del pipeline de preprocesamiento de imágenes MRI

Carga y Conversión a Escala de Grises

Cada imagen MRI se carga utilizando OpenCV en modo escala de grises (`cv2.IMREAD_GRAYSCALE`), eliminando información cromática irrelevante para el análisis textural.

Mejora de Contraste con CLAHE

Para abordar problemas de iluminación desigual y bajo contraste, se aplica el algoritmo CLAHE (Contrast Limited Adaptive Histogram Equalization). A diferencia de la ecualización global de histograma, CLAHE opera en regiones locales de la imagen:

- **Clip Limit:** 3.0 - Limita la amplificación del ruido
- **Tile Grid Size:** 8×8 - Divide la imagen en 64 regiones para procesamiento local

Este método mejora significativamente la visibilidad de estructuras sutiles en el tejido cerebral, como se observa en la Figura 3.3b.

Filtrado Bilateral para Reducción de Ruido

Posteriormente, se aplica un filtro bilateral que preserva bordes mientras reduce ruido:

- **Diámetro (d):** 9 píxeles - Tamaño del vecindario
- **Sigma Color:** 75 - Controla la influencia de diferencias de intensidad
- **Sigma Space:** 75 - Controla la influencia espacial

Este filtro es particularmente efectivo para imágenes médicas ya que mantiene los bordes de las estructuras anatómicas mientras suaviza regiones homogéneas (Figura 3.3c).

Segmentación Adaptativa

Para aislar las regiones cerebrales relevantes, se genera una máscara binaria mediante umbralización adaptativa:

$$M(x, y) = \begin{cases} 255 & \text{si } I_{filtered}(x, y) > T_{local}(x, y) \\ 0 & \text{en otro caso} \end{cases} \quad (3.1)$$

donde T_{local} se calcula utilizando:

- **Método:** ADAPTIVE_THRESH_MEAN_C - Umbral basado en la media local
- **Block Size:** 15 píxeles - Tamaño de la vecindad para cálculo local
- **Constante C:** 5 - Valor sustraído de la media

Posteriormente, se aplican operaciones morfológicas de cierre para eliminar pequeños agujeros y suavizar la máscara:

$$M_{closed} = (M \bullet K)_{iter=1} \quad (3.2)$$

donde K es un elemento estructurante elíptico de 3×3 píxeles.

Extracción de Región de Interés (ROI)

La máscara segmentada se utiliza para extraer la región de interés mediante operaciones bit a bit:

$$I_{ROI} = I_{enhanced} \wedge M_{closed} \quad (3.3)$$

Luego, se calcula el rectángulo delimitador de la máscara para recortar la ROI:

$$(x, y, w, h) = (M_{closed}) \quad (3.4)$$

$$I_{ROI_cropped} = I_{ROI}[y : y + h, x : x + w] \quad (3.5)$$

Este paso elimina el fondo irrelevante y reduce la dimensionalidad para el análisis GLCM, como se muestra en la Figura 3.3e.

Validación y Control de Calidad

Cada etapa del pipeline incluye validaciones para garantizar la calidad del procesamiento:

- Verificación de carga correcta de imágenes
- Detección de imágenes uniformes ($\sigma_{mask} = 0$)
- Manejo de excepciones en cálculo de GLCM
- Monitoreo de progreso y reporte de errores

Este pipeline robusto permite procesar eficientemente el dataset completo de 2,914 imágenes, generando ROIs limpias y consistentes para la posterior extracción de características GLCM.




Figura 3.3: Resultados intermedios del pipeline de preprocesamiento. (a) Imagen MRI original. (b) Mejora de contraste mediante CLAHE. (c) Reducción de ruido con filtro bilateral. (d) Máscara binaria generada por segmentación adaptativa. (e) Región de interés (ROI) final recortada.

Arquitectura del Modelo ANFIS

El sistema implementa un modelo ANFIS (Adaptive Neuro-Fuzzy Inference System) de tipo Sugeno de primer orden, diseñado específicamente para la clasificación de tumores cerebrales. La arquitectura, ilustrada en la Figura 3.4, consta de 5 capas que transforman las características GLCM en una probabilidad de tumor.




Figura 3.4: Arquitectura detallada del modelo ANFIS implementado

Capa 1: Fuzzificación

Esta capa transforma las 7 características GLCM normalizadas en grados de pertenencia a conjuntos difusos mediante funciones gaussianas. Para cada característica x_i , se calculan dos grados de membresía: "bajo" y "alto".

$$\mu_{ij}(x_i) = \exp \left(-\frac{1}{2} \left(\frac{x_i - c_{ij}}{\sigma_{ij}} \right)^2 \right) \quad (3.6)$$

- **Input:** 7 características $[x_1, x_2, \dots, x_7]$ normalizadas
- **Conjuntos:** "bajo" y "alto" por cada característica
- **Total:** 14 funciones de membresía (7 características $\times$ 2 conjuntos)
- **Parámetros:** Centros c_{ij} y anchos σ_{ij} (28 parámetros totales)

La implementación en Python utiliza la función `gaussmf` de `scikit-fuzzy`:

```
def compute_weights(x, mf_params):
    """Calcula grados de membresía para un vector de entrada x"""
    grados = []
    for i in range(n_vars):
        # Parámetros para 'bajo' y 'alto'
        mu_b, sig_b = mf_params[2*i + 0] # conjunto 'bajo'
        mu_a, sig_a = mf_params[2*i + 1] # conjunto 'alto'

        grados.append({
            'bajo': gaussmf(x[i], mu_b, sig_b),
            'alto': gaussmf(x[i], mu_a, sig_a)
        })
    return grados
```

Ejemplo numérico: Para una característica $x_3 = 0,75$ con parámetros $bajo = (0,3,0,2)$ y $alto = (0,7,0,15)$:

$$\mu_{bajo}(0,75) = \exp \left(-\frac{1}{2} \left(\frac{0,75 - 0,3}{0,2} \right)^2 \right) \approx 0,043 \quad (3.7)$$

$$\mu_{alto}(0,75) = \exp \left(-\frac{1}{2} \left(\frac{0,75 - 0,7}{0,15} \right)^2 \right) \approx 0,945 \quad (3.8)$$

Capa 2: Evaluación de Reglas

Se generan sistemáticamente todas las combinaciones posibles de reglas difusas usando el producto cartesiano de los conjuntos "bajo" y "alto" para las 7 características:

$$reglas = \{bajo, alto\}^7$$

- **Total reglas:** $2^7 = 128$ reglas completas
- **Activación:** $w_j = \prod_{i=1}^7 \mu_{i,etq_j}(x_i)$ donde etq_j es la etiqueta de la característica i en la regla j
- **Implementación:** Uso eficiente de `itertools.product` para generación

```
from itertools import product

# Configuración global del modelo
n_vars = 7 # Número de características GLCM
labels = ['bajo', 'alto']
reglas = list(product(labels, repeat=n_vars))

def compute_rule_activations(grados):
    """Calcula activaciones para todas las reglas"""
    w = np.array([
        np.prod([grados[i][etq] for i, etq in enumerate(regla)])
        for regla in reglas
    ])
    # Evitar división por cero
    return w / w.sum() if w.sum() > 0 else w
```

Ejemplo de regla: La regla 42 podría ser: "SI x_1 es alto Y x_2 es bajo Y x_3 es alto Y x_4 es bajo Y x_5 es bajo Y x_6 es alto Y x_7 es bajo ENTONCES ..."

Capa 3: Normalización

Los pesos de activación se normalizan para que sumen 1, transformándolos en pesos relativos:

$$\bar{w}_j = \frac{w_j}{\sum_{k=1}^{128} w_k} \quad (3.9)$$

Esta normalización es crucial porque:

- Convierte activaciones absolutas en contribuciones relativas
- Asegura estabilidad numérica en la agregación final
- Facilita la interpretación de la importancia de cada regla

Capa 4: Consecuentes Lineales

Cada regla produce una salida lineal con los parámetros de Sugeno de primer orden. Para la regla j :

$$y_j = p_{j0} + p_{j1}x_1 + p_{j2}x_2 + \cdots + p_{j7}x_7 \quad (3.10)$$

En forma vectorial compacta:

$$y_j = \mathbf{p}_j^T \mathbf{x} + r_j \quad (3.11)$$

- $\mathbf{p}_j \in \mathbb{R}^7$: Coeficientes lineales para la regla j
- $r_j \in \mathbb{R}$: Término constante (sesgo)
- **Total parámetros lineales:** 128 reglas $\times$ 8 parámetros = 1,024 parámetros

Cálculo de Mínimos Cuadrados (LSE) y Matriz de Diseño F: Para cada conjunto de parámetros MF, se calculan los parámetros lineales óptimos resolviendo el sistema de ecuaciones lineales mediante mínimos cuadrados. El corazón de este cálculo es la **matriz de diseño F**, que captura la influencia ponderada de todas las reglas sobre cada muestra de entrenamiento.

Cada fila de **F** corresponde a una imagen del conjunto de entrenamiento, y cada columna corresponde a un término de los consecuentes ponderado por la activación de la regla:

$$\mathbf{F} = \begin{bmatrix} w_{1,1}x_{1,1} & \cdots & w_{1,1}x_{1,7} & w_{1,1} & \cdots & w_{128,1}x_{1,1} & \cdots & w_{128,1}x_{1,7} & w_{128,1} \\ w_{1,2}x_{2,1} & \cdots & w_{1,2}x_{2,7} & w_{1,2} & \cdots & w_{128,2}x_{2,1} & \cdots & w_{128,2}x_{2,7} & w_{128,2} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ w_{1,N}x_{N,1} & \cdots & w_{1,N}x_{N,7} & w_{1,N} & \cdots & w_{128,N}x_{N,1} & \cdots & w_{128,N}x_{N,7} & w_{128,N} \end{bmatrix} \quad (3.12)$$

Donde:

- N : Número de imágenes de entrenamiento
- $w_{j,k}$: Peso normalizado de la regla j para la imagen k (salida de la Capa 3)
- $x_{k,i}$: Valor de la característica i de la imagen k
- **Dimensiones:** N filas $\times$ (128×8) columnas $= N \times 1024$

Estructura de Columnas y Bloques: Las columnas de **F** se organizan en 128 bloques (uno por regla), donde cada bloque contiene 8 elementos:

- **Columnas 1-7 del bloque j :** $w_j \cdot x_1, \dots, w_j \cdot x_7$ (términos lineales)
- **Columna 8 del bloque j :** $w_j \cdot 1$ (término constante/sesgo)
- **Patrón:** Cada bloque j representa: $[w_j x_1, w_j x_2, \dots, w_j x_7, w_j]$

Implementación en Código: La construcción de la matriz **F** se implementa eficientemente en la función `solve_sugeno_params`:

```

def solve_sugeno_params(X, y, mf_params):
    """Calcula parámetros óptimos de Sugeno usando mínimos cuadrados"""
    N = X.shape[0] # Número de muestras
    R = len(reglas) # 128 reglas

    # Matriz de diseño: N × (R*(n_vars+1)) = N × 1024
    F = np.zeros((N, R * (n_vars + 1)))

    for k in range(N):
        w_bar = compute_weights(X[k], mf_params) # w_{j,k} para muestra k
        row = []
        for j in range(R):
            # Términos lineales: p_j1*x1 + ... + p_j7*x7
            row.extend(w_bar[j] * X[k]) # w_j * [x1, x2, ..., x7]
            # Término constante: r_j
            row.append(w_bar[j] * 1.0) # w_j * 1
        F[k] = row # Fila k completa

    # Resolver sistema F·theta = y usando mínimos cuadrados
    theta, residuals, rank, s = np.linalg.lstsq(F, y, rcond=None)
    return theta

```

Solución por Mínimos Cuadrados: El vector óptimo de parámetros θ se obtiene resolviendo:

$$\theta = (\mathbf{F}^T \mathbf{F})^{-1} \mathbf{F}^T \mathbf{y} \quad (3.13)$$

Esta solución minimiza el error cuadrático medio entre las predicciones del modelo ($\mathbf{F}\theta$) y las etiquetas reales $\mathbf{y}$.

Interpretación Geométrica: Cada fila de $\mathbf{F}$ representa cómo las 128 reglas (ponderadas por sus activaciones) contribuyen a la predicción de una imagen específica. La solución de mínimos cuadrados encuentra los parámetros θ que mejor “explican” las etiquetas reales “ $\mathbf{y}$ ” en este espacio de características expandido.

Ejemplo Numérico para una Muestra: Para una imagen k con características $\mathbf{x}_k = [0,8,0,3]$ (simplificado) y activaciones $\bar{w} = [0,1,0,4, \dots, 0,05]$:

$$\mathbf{F}_k = [0,1 \times 0,8, 0,1 \times 0,3, 0,1, 0,4 \times 0,8, 0,4 \times 0,3, 0,4, \dots, 0,05 \times 0,8, 0,05 \times 0,3, 0,05] \quad (3.14)$$

Propiedades y Consideraciones Numéricas

- $\mathbf{F}^T \mathbf{F}$ es una matriz de 1024×1024 que puede ser singular si hay reglas linealmente dependientes
- Se usa `np.linalg.lstsq` con `rcond=None` para manejar automáticamente posibles singularidades
- La solución es óptima en el sentido de mínimos cuadrados para los parámetros MF actuales

Integración en el Entrenamiento Híbrido: En cada evaluación de PSO, para una partícula dada:

1. Se reconstruyen los parámetros MF desde el vector de la partícula
2. Se calculan las activaciones $\bar{w}_{j,k}$ para todas las muestras y reglas
3. Se construye la matriz $\mathbf{F}$ completa ($N \times 1024$)
4. Se resuelve $\theta = LSE(\mathbf{F}, \mathbf{y})$
5. Se calcula el MSE usando $\mathbf{F}\theta$ como predicciones

Esta integración permite que PSO optimice eficientemente los 28 parámetros no lineales mientras LSE garantiza los óptimos 1024 parámetros lineales en cada iteración.

Capa 5: Agregación

La salida final es el promedio ponderado de todas las reglas:

$$y = \sum_{j=1}^{128} \bar{w}_j y_j = \sum_{j=1}^{128} \bar{w}_j (\mathbf{p}_j^T \mathbf{x} + r_j) \quad (3.15)$$

El valor resultante $y \in \mathbb{R}$ representa la salida continua del modelo, que luego se umbraliza:

- $y > 0,5$: Clasificado como tumor (etiqueta 1)
- $y \leq 0,5$: Clasificado como sano (etiqueta 0)

Implementación de la inferencia completa:

```
def anfis_predict(x, mf_params, theta):
    """Predicción para una sola muestra"""
    w_bar = compute_weights(x, mf_params)
    total = 0.0

    for j in range(len(reglas)):
        # Extraer parámetros para la regla j
        start_idx = j * (n_vars + 1)
        pj = theta[start_idx:start_idx + n_vars] # Coeficientes
        rj = theta[start_idx + n_vars]           # Sesgo

        # Calcular salida de la regla
        rule_output = np.dot(pj, x) + rj
        # Agregar contribución ponderada
        total += w_bar[j] * rule_output

    return 1 if total > 0.5 else 0
```

Inicialización Heurística de Parámetros

Los parámetros iniciales de las funciones de membresía se inicializan usando estadísticas robustas del dataset de entrenamiento:

```
def init_mf_params(X_train):
    """
    Inicialización heurística de (mu, sigma) para cada variable:
    - 'bajo': mean - std, sigma = 0.5*std
    - 'alto': mean + std, sigma = 0.5*std
    Devuelve array (14, 2) con parámetros para las 14 funciones
    """
    means = X_train.mean(axis=0)
    stds = X_train.std(axis=0)
    params = []
```

```
for m, s in zip(means, stds):  
    # Conjunto 'bajo': centrado en mean - std  
    params.append((m - s, 0.5 * s))  
    # Conjunto 'alto': centrado en mean + std  
    params.append((m + s, 0.5 * s))  
  
return np.array(params)
```

Justificación de la inicialización:

- Los centros se ubican en $\mu \pm \sigma$ para cubrir la variabilidad natural de los datos
- Los anchos se fijan en $0,5\sigma$ para asegurar solapamiento controlado entre conjuntos
- Esta inicialización acelera la convergencia del PSO al partir de una solución razonable

Algoritmo de Entrenamiento Híbrido

El modelo utiliza un enfoque de entrenamiento híbrido que combina PSO (Particle Swarm Optimization) para parámetros no lineales y LSE (Least Squares Estimation) para parámetros lineales, como se muestra en la Figura 3.5.




Figura 3.5: Diagrama del proceso de entrenamiento híbrido PSO-LSE

Función de Error para PSO

Se define una función de error basada en MSE (Mean Squared Error) que PSO minimiza:

```
def error_func(flat_params):
    """Función objetivo para PSO: minimizar MSE"""
    # Reconstruir parámetros MF desde vector plano
    mf_params = flat_params.reshape((-1, 2))

    # Calcular parámetros óptimos de Sugeno usando LSE
    theta_opt = solve_sugeno_params(X_train, y_train, mf_params)

    # Calcular predicciones para todo el conjunto
    y_hat = []
    for x in X_train:
        w_bar = compute_weights(x, mf_params)
        total = 0.0
        for j in range(len(reglas)):
            pj = theta_opt[j*(n_vars+1):j*(n_vars+1)+n_vars]
            rj = theta_opt[j*(n_vars+1)+n_vars]
            total += w_bar[j] * (np.dot(pj, x) + rj)
        y_hat.append(total)

    # Calcular y retornar MSE
    mse = np.mean((np.array(y_hat) - y_train) ** 2)
    return mse
```

Parámetros de PSO Implementados

La configuración específica de PSO optimizada para este problema:

```
# Parámetros de PSO para entrenamiento ANFIS
pso_params = {
    'swarmsize': 50,          # Tamaño del enjambre
    'maxiter': 20,           # Iteraciones máximas
    'pkip': 1.5,             # Coeficiente cognitivo
    'phig': 2.0,             # Coeficiente social
    'omega': 0.5,           # Factor de inercia
```

```

    'minstep': 1e-8,      # Paso mínimo para convergencia
    'minfunc': 1e-8,      # Mejora mínima para convergencia
}

```

Optimización con PSO

PSO optimiza los 28 parámetros no lineales (centros y anchos de las gaussianas):

Algorithm 1 Entrenamiento Híbrido ANFIS con PSO y LSE

```

1: Inicializar parámetros MF usando init_mf_params
2: Aplanar parámetros a vector:  $\mathbf{mf}_0 \in \mathbb{R}^{28}$ 
3: Definir límites de búsqueda:  $\mathbf{mf}_0 \pm 3,0$ 
4: for cada partícula en el enjambre de PSO do
5:   Reconstruir parámetros MF:  $\mathbf{mf} = \text{reshape}(\text{particula})$ 
6:   Calcular  $\theta$  óptimo usando LSE:  $\theta = (\mathbf{F}^T \mathbf{F})^{-1} \mathbf{F}^T \mathbf{y}$ 
7:   Predecir todo el conjunto de entrenamiento:  $\hat{\mathbf{y}} = \mathbf{F}\theta$ 
8:   Calcular error MSE:  $E = \frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_k)^2$ 
9:   Actualizar mejor posición personal y global
10: end for
11: Reconstruir mejores parámetros MF y  $\theta$ 
12: return  $\mathbf{mf}_{opt}, \theta_{opt}$ 

```

Implementación del Entrenamiento Completo

```

def train_anfis(X_train, y_train, swarmsize=50, maxiter=20):
    """Entrenamiento completo del modelo ANFIS"""
    # 1. Inicialización de parámetros MF
    mf0 = init_mf_params(X_train).reshape(-1)

    # 2. Definir límites de búsqueda
    mins = mf0 - 3.0
    maxs = mf0 + 3.0

    # 3. Ejecutar PSO
    print("Iniciando optimización PSO...")
    start_time = time.time()

```

```

opt_flat, opt_err = pso(
    error_func, mins, maxs,
    swarmsize=swarmsize, maxiter=maxiter,
    phip=1.5, phig=2.0, omega=0.5
)

elapsed = time.time() - start_time
print(f"PSO completado en {timedelta(seconds=int(elapsed))}")
print(f"Error final: {opt_err:.6f}")

# 4. Reconstruir parámetros finales
mf_opt = opt_flat.reshape((-1, 2))
theta_opt = solve_sugeno_params(X_train, y_train, mf_opt)

return mf_opt, theta_opt

```

Ventajas del Enfoque Híbrido Implementado

- **Eficiencia computacional:** Separa optimización lineal (LSE) y no lineal (PSO)
- **Convergencia rápida:** LSE proporciona solución óptima instantánea para parámetros lineales en cada iteración
- **Robustez:** PSO explora eficientemente el espacio de parámetros no lineales evitando mínimos locales
- **Interpretabilidad:** Mantiene la estructura de reglas difusas comprensibles para expertos médicos
- **Generalización:** El enfoque híbrido previene sobreajuste mejor que métodos puramente neuronales

Ejemplo Completo de Inferencia

Para una nueva imagen con características $x = [0,8, 0,3, 0,6, 0,4, 0,5, 0,7, 0,2]$:

1. **Fuzzificación:** Calcular 14 grados de membresía

$$\begin{array}{ll}
\mu_{bajo}(x_1) = 0,12 & \mu_{alto}(x_1) = 0,88 \\
\mu_{bajo}(x_2) = 0,85 & \mu_{alto}(x_2) = 0,15 \\
\vdots & \vdots
\end{array}$$

2. **Reglas:** Evaluar 128 activaciones w_j

$$w_{15} = 0,88 \times 0,85 \times 0,92 \times 0,78 \times 0,65 \times 0,95 \times 0,45 = 0,156$$

$$w_{42} = 0,12 \times 0,15 \times 0,08 \times 0,22 \times 0,35 \times 0,05 \times 0,55 = 1,2 \times 10^{-6}$$

3. **Normalización:** Calcular $\bar{w}_j = w_j / \sum w_k$

4. **Consecuentes:** Computar $y_j = \mathbf{p}_j^T \mathbf{x} + r_j$

5. **Agregación:** $y = \sum \bar{w}_j y_j = 1,03$

6. **Umbralización:** $\hat{y} = 1$ (tumor detectado)

3.2. Interfaz Gráfica de Usuario

El sistema incluye una interfaz gráfica desarrollada en Python que permite interactuar con el modelo ANFIS de manera intuitiva. La interfaz principal (Figura 3.6) organiza las funcionalidades en secciones lógicas.




Figura 3.6: Interfaz general del sistema ANFIS para detección de tumores cerebrales

Módulo de Gestión de Datos

La sección de datos (Figura 3.7) facilita la carga de los datos.




Figura 3.7: Módulo de gestión y visualización de datos

Módulo de Ejecución

El panel de ejecución (Figura 3.8) controla el proceso de entrenamiento, dando opciones de usabilidad para modelos, características procesadas previas, entre otros.




Figura 3.8: Panel de control para ejecución del entrenamiento

Herramientas Adicionales

La sección de herramientas (Figura 3.9) proporciona funcionalidades para limpieza, acceso al visualizador gráfico, así como acceso al menú del configurador.



Figura 3.9: Panel de herramientas adicionales del sistema

Módulo de Visualización

El visualizador (Figura 3.10) permite analizar resultados, mostrando reglas difusas generadas, importancia de características y métricas de desempeño, este tal como su nombre menciona permite visualizar datos csv, txt e imágenes.




Figura 3.10: Interfaz del Visualizador de resultados y reglas

Módulo de Configuración

El configurador (Figura 3.11) es una ventana especializada que permite configurar distintas partes del programa.

- **Directorio:** Ajuste de directorios predeterminados.
- **Procesamiento:** Configuración en directorio de imágenes intermedias (Figura 3.3) y guardado de estas para depurar.
- **Entrenamiento:** Ajuste en ciertos parámetros del entrenamiento PSO
- **Sistema Cache:** Configuración para que datos guardar en cache
- **Análisis:** Configuración sobre que datos guardar en análisis, directorio y cuantas reglas.




Figura 3.11: Interfaz del Configurador de parámetros ANFIS

Capítulo 4

Resultados y Análisis

4.1. Implementación Técnica

Tecnologías Utilizadas

Cuadro 4.1: Tecnologías para el Desarrollo de la Interfaz

Tecnología	Propósito	Versión
Tkinter / TtkBootstrap	Construcción de la interfaz gráfica y estilos modernos	1.16.0
Matplotlib	Visualización de gráficos y resultados analíticos	3.10.5
OpenCV	Procesamiento y visualización de imágenes	4.12.0.88
Pandas	Manipulación y análisis de datos tabulares	2.3.2
NumPy	Cálculos numéricos y operaciones matriciales	2.2.6
Scikit-learn	Entrenamiento y evaluación de modelos de aprendizaje automático	1.7.1
Scikit-image	Procesamiento digital de imágenes científicas	0.25.2
Scikit-fuzzy	Implementación de sistemas de inferencia difusa	0.5.0
PyInstaller	Empaquetado y generación de ejecutables portables	6.16.0

Plataforma Informática

Cuadro 4.2: Especificaciones de hardware y software utilizadas en el desarrollo

Hardware	Especificación
Especificaciones de GPU	
Modelo de GPU	RTX 2060 SUPER
Cuda Cores	2176
SM	34
Base Clock (MHz)	1470
Memoria	8GB GDDR6
Velocidad de Memoria	14 Gbps
Especificaciones Memoria RAM	
Capacidad	32GB
Velocidad base (MHz)	5200
Tipo de Memoria	DDR5
Especificaciones de CPU	
Modelo de CPU	Ryzen 5 8400F
Cantidad de núcleos	6
Cantidad de hilos	12
Base Clock (GHz)	4.2
Software	Especificación
Sistema Operativo	Windows 11
Lenguaje	Python 3.12.3

4.2. Evaluación del Modelo ANFIS

El modelo ANFIS desarrollado muestra un excelente rendimiento en la detección de tumores cerebrales, como se evidencia en las métricas de evaluación presentadas en la Figura 4.1.




Figura 4.1: Evaluación completa del modelo ANFIS que incluye matriz de confusión, curva ROC y métricas de rendimiento detalladas

Métricas de Rendimiento

- **Precisión:** 96.43 % - Indica la capacidad del modelo para clasificar correctamente los casos positivos, con solo un 3.57 % de falsos positivos.
- **Sensibilidad:** 88.24 % - Muestra la efectividad en detectar tumores reales, con una tasa de falsos negativos del 11.76 %.
- **Especificidad:** 97.53 % - Demuestra alta capacidad para identificar correctamente casos sin tumor, crucial para evitar diagnósticos innecesarios.
- **Puntuación F1:** 92.15 % - Balance óptimo entre precisión y recall, indicando un rendimiento equilibrado.

- **AUC:** 96.43 % - Excelente capacidad discriminativa del modelo, cercana al rendimiento perfecto.

Análisis de la Matriz de Confusión

La matriz de confusión (Figura 4.1) revela:

- **Verdaderos Positivos:** 270 casos correctamente identificados como tumores
- **Verdaderos Negativos:** 395 casos correctamente identificados como sanos
- **Falsos Positivos:** 10 casos (tejido sano clasificado como tumor)
- **Falsos Negativos:** 36 casos (tumor no detectado)

Con esto nos podemos dar cuenta que si bien a rasgos generales los valores son bastantes positivos, tenemos cierta tendencia de falsos negativos, es puede deberse tanto por el tamaño total de imágenes así como el estado de la misma, en nuestro data set se poseen MRI que poseen poses distintas, tamaños y otros.

Análisis de la Curva ROC

La curva ROC (Figura 4.1) confirma el alto rendimiento del modelo, con un área bajo la curva de 96.43 %, indicando una separación casi perfecta entre las clases. La curva se mantiene cerca de la esquina superior izquierda, demostrando altas tasas de verdaderos positivos y bajas tasas de falsos positivos en todos los umbrales.

4.3. Análisis de Características GLCM

El análisis de importancia de características revela la distribución de influencia mostrada en la Figura 4.2.




Figura 4.2: Importancia relativa de las características GLCM en el modelo ANFIS, calculada a partir del impacto acumulado de todas las reglas

Jerarquía de Características

- **ASM (Angular Second Moment):** Característica más influyente (1,958,721.33), relacionada con la homogeneidad textural de la imagen. Valores altos indican texturas uniformes, típicas de tejido sano, mientras que valores bajos sugieren heterogeneidad asociada a tumores.
- **Energía:** Segunda en importancia (1,168,611.08), indicando la distribución de energía en la matriz GLCM. Refleja la regularidad de los patrones texturales, siendo crucial para distinguir entre tejido normal y patológico.
- **Homogeneidad:** Tercera posición (960,107.66), reflejando la uniformidad textural. Las regiones tumorales suelen mostrar menor homogeneidad debido a la presencia de necrosis, edema y variaciones celulares.
- **Entropía:** Cuarta en importancia (155,486.94), relacionada con la aleatoriedad textural. Los tumores suelen presentar mayor entropía debido a su naturaleza desorganizada.

- **Media:** Quinta posición (34,811.83), representando el valor promedio de intensidad. Aunque menos influyente, contribuye a caracterizar la densidad del tejido.
- **Contraste y Varianza:** Menos influyentes pero aún relevantes para el modelo, contribuyendo a capturar diferencias locales en textura y brillo.

Implicaciones Clínicas

Este patrón de importancia sugiere que las características relacionadas con la regularidad y uniformidad textural son las más discriminativas para la detección de tumores cerebrales, coincidiendo con hallazgos reportados en la literatura médica sobre las propiedades texturales de las lesiones cerebrales.

4.4. Análisis de Reglas ANFIS

Distribución de Importancia de Reglas

El análisis de las 128 reglas generadas por el modelo ANFIS (Figura 4.3) muestra una distribución altamente sesgada donde pocas reglas dominan el comportamiento del modelo.




Figura 4.3: Distribución de importancia entre las 128 reglas ANFIS generadas por el modelo, mostrando el dominio de un subconjunto pequeño de reglas

- Solo **20 reglas** tienen activación media superior a 0.01, indicando que la mayoría de las decisiones se toman basándose en un subconjunto pequeño de reglas.
- Las **10 reglas más importantes** concentran el 85 % del poder predictivo, demostrando la eficiencia del modelo en identificar patrones clave.
- Existe una caída exponencial en la importancia, donde la Regla 0 tiene una importancia de 534,671.61 mientras que la regla 32 tiene solo 399,244, luego nos siguen reglas como la 23,87,16 con valores bastantes similares, por ejemplo la regla 23 posee 142,243.

Mapa de Calor de Reglas

El mapa de calor de la Figura 4.4 revela patrones complejos de activación y permite identificar clusters de reglas con comportamientos similares.




Figura 4.4: Mapa de calor mostrando patrones de activación en las reglas más importantes del sistema ANFIS, organizadas por similitud de comportamiento

4.5. Interpretación Clínica Basada en Evidencia

Toda esta información proviene de archivos de análisis de tipo txt, tal como lo es el archivo de texto de reporte de reglas (Listing A.1).

Reglas de Homogeneidad Alta y Tejido Sano

La afirmación sobre las reglas 23, 87 y 16 se basa en el análisis de sus parámetros y condiciones:

- **Regla 16:** Condiciones: Contraste bajo, ASM bajo, Homogeneidad alto, Energía bajo, Media bajo, Entropía bajo, Varianza bajo.
 - **Bias:** -433,434.60 (negativo)
 - **Parámetros clave:** ASM: 1,105,518.56 (positivo), Energía: 850,292.50 (positivo)
 - **Interpretación:** Aunque el bias es negativo (favorece no tumor), los parámetros positivos de ASM y Energía sugieren que esta regla podría activarse en patrones específicos más que exclusivamente en tejido sano.
- **Regla 23:** Condiciones: Contraste bajo, ASM bajo, Homogeneidad alto, Energía bajo, Media alto, Entropía alto, Varianza alto.
 - **Bias:** 1,586,297.97 (positivo grande)
 - **Parámetros clave:** ASM: -4,570,130.40 (negativo grande), Energía: 1,026,649.68 (positivo)
 - **Interpretación:** El bias positivo fuerte sugiere tendencia a tumor, no a tejido sano.
- **Regla 87:** Condiciones: Contraste alto, ASM bajo, Homogeneidad alto, Energía bajo, Media alto, Entropía alto, Varianza alto.
 - **Bias:** 1,427,018.86 (positivo grande)
 - **Parámetros clave:** Energía: -1,709,753.20 (negativo grande)
 - **Interpretación:** Bias positivo indica tendencia a tumor.

Reglas de ASM Alto y Detección de Tumores

La afirmación sobre las reglas 32 y 34 se sustenta en:

- **Regla 32:** Condiciones: Contraste bajo, ASM alto, Homogeneidad bajo, Energía bajo, Media bajo, Entropía bajo, Varianza bajo.
 - **Bias:** 3,544,426.23 (positivo muy grande)
 - **Parámetros clave:** ASM: 4,808,606.09 (positivo muy grande), Homogeneidad: -2,482,939.29 (negativo grande)
 - **Importancia total:** 399,244.39 (segunda más importante)

- **Interpretación:** La combinación de bias positivo grande y parámetro ASM positivo grande confirma fuerte tendencia a detectar tumores.
- **Regla 34:** Condiciones: Contraste bajo, ASM alto, Homogeneidad bajo, Energía bajo, Media bajo, Entropía alto, Varianza bajo.
 - **Bias:** 158,118.36 (positivo)
 - **Parámetros clave:** ASM: 3,752,640.19 (positivo grande), Energía: -1,931,449.76 (negativo grande)
 - **Importancia total:** 99,075.31 (séptima más importante)
 - **Interpretación:** Parámetro ASM positivo grande con bias positivo indica detección de patrones tumorales.

Conclusión: Las reglas con ASM alto (32 y 34) sí muestran evidencia clara de asociación con detección de tumores, basado en sus parámetros positivos y alta importancia en el modelo.

Patrones Confirmados por Evidencia

- **Tejido Sano:** Regla 0 (bajas en todas las características) con bias negativo (-3,431,737.75) claramente asociada a no tumor.
- **Tumores Definitivos:** Regla 119 (altas en 6 de 7 características) con bias negativo pero parámetros que compensan, activándose en tumores avanzados.
- **Patrones Específicos:** Regla 32 (ASM alto + Homogeneidad baja) como marcador confiable de patrones tumorales.

Fortalezas del Modelo

1. **Interpretabilidad:** Cada regla proporciona insight sobre qué combinaciones de características son relevantes.
2. **Robustez:** Múltiples reglas cubren diferentes patrones patológicos.
3. **Eficiencia:** Solo 20 reglas principales manejan la mayoría de las decisiones.

4. **Precisión Clínica:** Alta especificidad minimiza falsos positivos.

El modelo ANFIS demuestra ser no solo preciso, sino también interpretable, permitiendo a los radiólogos entender las bases de las decisiones del sistema, lo que es crucial para aplicaciones médicas. La combinación de alto rendimiento predictivo con transparencia en la toma de decisiones posiciona este modelo como una herramienta valiosa para el diagnóstico asistido de tumores cerebrales.

4.6. Conclusiones del Análisis

El modelo ANFIS desarrollado demuestra ser no solo preciso (AUC: 96.43 %), sino también interpretable, permitiendo a los radiólogos entender las bases de las decisiones del sistema. La combinación de alto rendimiento predictivo con transparencia en la toma de decisiones posiciona este modelo como una herramienta valiosa para el diagnóstico asistido de tumores cerebrales.

La arquitectura del sistema, desde el preprocesamiento de imágenes (Figura 3.3) hasta la interfaz de usuario final (Figura 3.6), proporciona un flujo de trabajo integrado que facilita la adopción clínica del sistema, mientras que el análisis detallado de reglas (Figuras 4.3, 4.4) asegura que las decisiones puedan ser validadas y comprendidas por el personal médico.

El sistema logra un balance óptimo entre rendimiento computacional y precisión diagnóstica, con una especificidad del 97.53 % que minimiza los falsos positivos y una sensibilidad del 88.24 % que asegura la detección de la mayoría de los tumores clínicamente relevantes, este último valor puede mejorarse, cambiando algoritmos, modificando ciertos patrones, ajustando tamaños, entre otras ideas.

Capítulo 5

Conclusiones

En este trabajo se desarrolló e implementó un sistema ANFIS para la detección automática de tumores cerebral. A continuación, se presentan las conclusiones organizadas en relación con los objetivos específicos planteados inicialmente.

1. Con respecto al objetivo de implementar un modelo ANFIS optimizado con PSO: Se logró construir un modelo neuro-difuso robusto, entrenado mediante un enfoque híbrido que combina la optimización por enjambre de partículas (PSO) para los parámetros no lineales de las funciones de membresía y el método de mínimos cuadrados (LSE) para los parámetros lineales de los consecuentes. Este modelo, alimentado con 7 características texturales GLCM, demostró un alto rendimiento, alcanzando una precisión del **96.43 %**, un AUC de **96.43 %** y una especificidad del **97.53 %**. Estos resultados validan la efectividad de la arquitectura propuesta para la tarea de clasificación difusa binaria (tumor vs. sano).

2. Con respecto al objetivo de diseñar una interfaz gráfica de usuario intuitiva y portable: Se diseñó y desarrolló una interfaz gráfica completa utilizando Tkinter y TTKBootstrap, la cual integra de manera fluida todas las etapas del sistema: desde la carga y preprocesamiento de imágenes hasta la ejecución del modelo ANFIS y la visualización de resultados. La portabilidad del sistema se garantizó mediante PyInstaller, generando un ejecutable independiente que no requiere una instalación compleja de Python o sus librerías, facilitando así su potencial despliegue.

3. Con respecto al objetivo de evaluar el desempeño y analizar la interpretabilidad: El sistema fue evaluado rigurosamente, obteniendo métricas de clasificación que confirman su alto rendimiento. Además, se

realizó un análisis exhaustivo de la interpretabilidad del modelo a través de las 128 reglas difusas generadas. Este análisis reveló que un subconjunto pequeño de reglas (aprox. 20) concentra la mayor parte del poder predictivo, y permitió identificar patrones comprensibles, como la fuerte asociación entre un “ASM alto” combinado con “Homogeneidad baja” y la detección de tumores.

En resumen, este trabajo no solo cumplió satisfactoriamente con todos sus objetivos específicos, sino que demuestra la posibilidad de crear un sistema neuro-difuso adaptativo para la clasificación y/o detección de tumores cerebrales, sumado a la clara demostración de una interfaz gráfica intuitiva y cómoda, con todo lo mencionado anteriormente le sumamos el hecho de haberse realizado por Python, lo que nos permite replicabilidad, además de no estar encerrado en un entorno privativo como lo es MATLAB, con todo esto, mas lo mencionado anteriormente, se puede decir con total confianza que se cumplio los objetivos.

Trabajos Futuros

Como trabajo futuro se tiene varios puntos, siendo uno de los mas importantes lograr una mejora en los valores de sensibilidad, si bien un 88 % es bastante no esta a la par con el resto de las metricas que se tenian, por lo tanto para realizar estas mejoras se pueden hacer cambios tales como:

- **Ajuste Threshold:** Pasar de usar un treshold estandar donde usamos un valor fijo, a pasar a usar un treshold mas dinámico, que nos permita entender que por ejemplo no siempre los valores de pertenencia para tumores están por sobre 0.5, si no que por ejemplo pueden estar mas cercano 0.7 u otros, de esta manera se usaría en su totalidad el sistema difuso.
- **Regular parámetros Sugeno:** Si bien el código se auto corrige con PSO, esto mismo provoca datos demasiados grandes como se logro comprobar en la sección de interpretación clínica 4.5, con esto también podríamos prevenir posible sobre ajustes o problemáticas por valores extremadamente altos.

- **Algoritmo:** Si bien PSO nos ha servido de manera estupenda, sigue siendo un algoritmo en cierta medida de fuerza bruta, dependemos de la totalidad del enjambre, cuanta confianza existe, y dentro de todo eso existe cierto azar, en pruebas iniciales, era muy probable encontrar resultados óptimos y en siguientes pruebas resultados desastrosos, esto debido a que se encontraban mínimos locales, usar algoritmo mejor preparados es un cambio necesario.

Fuera de estos cambios que permitirían una mejoría en los resultados de métricas, se suma el hecho de agregar la capacidad de usar este sistema ANFIS con múltiples categorías, sistema el cual en cierta medida se logro realizar, pero su implementación se omitió por fines prácticos de tiempo, de querer verlo este se encontrara en el repositorio A.1, con todo esto se tendrían mejoras mas que sustanciales para el futuro de este proyecto.

Bibliografía

- [1] Sharma, Minakshi y Sourabh Mukharjee: *Artificial Neural Network Fuzzy Inference System (ANFIS) For Brain Tumor Detection*. International Journal of Advanced Computer Science and Applications, 13(1):45–52, 2022. <https://arxiv.org/pdf/1212.0059>, Aplicación de ANFIS con características GLCM para clasificación de tumores cerebrales en imágenes MRI.
- [2] Al-ali, Afnan, Omar Elharrouss, Uvais Qidwai y Somaya Al-Maadeed: *ANFIS-Net for automatic detection of COVID-19*. Scientific Reports, 11:17318, 2021. Demostración de efectividad de ANFIS en diagnóstico médico por imágenes de rayos X.
- [3] Mohanaiah, P., P. Sathyanarayana y L. Gurukumar: *Image Texture Feature Extraction Using GLCM Approach*. International Journal of Scientific and Research Publications, 3(5):1–5, 2013. <http://www.ijsrp.org/research-paper-0513/ijsrp-p1750.pdf>, Implementación eficiente de características GLCM en FPGA para aplicaciones en tiempo real.
- [4] Zadeh, Lotfi A, King Sun Fu y cols.: *Fuzzy sets and their applications to cognitive and decision processes*. Academic press, 1975. Fundamentos teóricos de conjuntos difusos y sus aplicaciones.
- [5] Haralick, Robert M, Karthikeyan Shanmugam y Its'Hak Dinstein: *Textural features for image classification*. IEEE Transactions on systems, man, and cybernetics, 3(6):610–621, 1973. Trabajo seminal que introduce las matrices de co-ocurrencia de niveles de gris (GLCM) para análisis de textura.

- [6] Jang, Jyh Shing Roger: *ANFIS: adaptive-network-based fuzzy inference system*. IEEE transactions on systems, man, and cybernetics, 23(3):665–685, 1993. Propuesta original de sistemas de inferencia neuro-difusa adaptativa.
- [7] Nickparvar, Masoud: *Brain Tumor MRI Dataset*, 2021. <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>, visitado el 2025-10-17, Conjunto de datos público de imágenes MRI de tumores cerebrales.
- [8] Medicine, Johns Hopkins: *Meningioma Grading*, 2021. <https://www.hopkinsmedicine.org/health/conditions-and-diseases/meningioma-grading>, Accessed 2025-10-19.
- [9] Watts, J., G. Box, A. Galvin, P. Brothie, N. Trost y T. Sutherland: *Magnetic resonance imaging of meningiomas: a pictorial review*. Insights into Imaging, 5(1):113–122, 2014.
- [10] National Cancer Institute: *Meningioma*, 2020. <https://www.cancer.gov/rare-brain-spine-tumor/espanol/tumores/meningioma>, Accessed 2025-10-19.
- [11] World Health Organization: *Cancer Today*, 2025. https://gco.iarc.who.int/today/en/dataviz/bars?mode=cancer&key=crude_rate&group_populations=0, Global Cancer Observatory.
- [12] Kennedy, James y Russell Eberhart: *Particle swarm optimization*. Proceedings of ICNN'95-international conference on neural networks, 4:1942–1948, 1995. Introducción del algoritmo de optimización por enjambre de partículas.

Anexos

Apéndice A

Anexo Técnico – Códigos Fuente

A.1. Repositorio Completo

El desarrollo completo del sistema, incluyendo todos los módulos, pruebas unitarias, documentación y ejemplos de uso, está disponible en el repositorio GitHub: https://github.com/Blackcito/ANFIS/tree/main/Modelo_anfis_ajustado.

Dentro del mismo repositorio existen otras carpetas con versiones distintas a la usada en este modelo.

A.2. Análisis Reglas.txt

```
1 =====
2 AN LISIS DE REGLAS ANFIS - DETECCI N DE TUMORES CEREBRALES
3 =====
4
5 Total de reglas generadas: 128
6 Reglas con activaci n > 0.01: 20
7 Top 10 reglas m s importantes:
8
9
10 --- REGLA #1 ( ndice : 0) ---
11 Condici n: SI Contraste es bajo Y ASM es bajo Y
    Homogeneidad es bajo Y Energ a es bajo Y Media es bajo Y
    Entrop a es bajo Y Varianza es bajo
12 Activaci n media: 0.0861
13 Magnitud par metros: 6212031.5643
```

```
14 Importancia total: 534671.6077
15 Bias: -3431737.7492
16 Caracter sticas m s influyentes:
17   - ASM: 3866652.8431
18   - Homogeneidad: 2489823.5605
19   - Energ a: -2376216.2530
20
21 --- REGLA #2 ( ndice : 32) ---
22 Condici n: SI Contraste es bajo Y ASM es alto Y
   Homogeneidad es bajo Y Energ a es bajo Y Media es bajo Y
   Entrop a es bajo Y Varianza es bajo
23 Activaci n media: 0.0588
24 Magnitud par metros: 6790671.7801
25 Importancia total: 399244.3912
26 Bias: 3544426.2271
27 Caracter sticas m s influyentes:
28   - ASM: 4808606.0949
29   - Homogeneidad: -2482939.2862
30   - Energ a: -2064602.6902
31
32 --- REGLA #3 ( ndice : 23) ---
33 Condici n: SI Contraste es bajo Y ASM es bajo Y
   Homogeneidad es alto Y Energ a es bajo Y Media es alto Y
   Entrop a es alto Y Varianza es alto
34 Activaci n media: 0.0285
35 Magnitud par metros: 4992279.8587
36 Importancia total: 142243.0391
37 Bias: 1586297.9748
38 Caracter sticas m s influyentes:
39   - ASM: -4570130.3959
40   - Energ a: 1026649.6830
41   - Homogeneidad: -673687.4658
42
43 --- REGLA #4 ( ndice : 87) ---
44 Condici n: SI Contraste es alto Y ASM es bajo Y
   Homogeneidad es alto Y Energ a es bajo Y Media es alto Y
   Entrop a es alto Y Varianza es alto
45 Activaci n media: 0.0594
46 Magnitud par metros: 2303890.9694
47 Importancia total: 136878.3340
48 Bias: 1427018.8607
49 Caracter sticas m s influyentes:
50   - Energ a: -1709753.2040
51   - Homogeneidad: -565651.8046
52   - ASM: 166969.0798
```

```
53 |
54 | --- REGLA #5 ( ndice : 16) ---
55 | Condici n: SI Contraste es bajo Y ASM es bajo Y
    | Homogeneidad es alto Y Energ a es bajo Y Media es bajo Y
    | Entrop a es bajo Y Varianza es bajo
56 | Activaci n media: 0.0893
57 | Magnitud par metros: 1492585.7865
58 | Importancia total: 133224.7170
59 | Bias: -433434.6033
60 | Caracter sticas m s influyentes:
61 | - ASM: 1105518.5603
62 | - Energ a: 850292.4955
63 | - Homogeneidad: 305711.9550
64 |
65 | --- REGLA #6 ( ndice : 18) ---
66 | Condici n: SI Contraste es bajo Y ASM es bajo Y
    | Homogeneidad es alto Y Energ a es bajo Y Media es bajo Y
    | Entrop a es alto Y Varianza es bajo
67 | Activaci n media: 0.0304
68 | Magnitud par metros: 4099806.8534
69 | Importancia total: 124506.2331
70 | Bias: -2483853.2355
71 | Caracter sticas m s influyentes:
72 | - ASM: 3228781.0018
73 | - Energ a: 397756.8797
74 | - Entrop a: 235674.1121
75 |
76 | --- REGLA #7 ( ndice : 34) ---
77 | Condici n: SI Contraste es bajo Y ASM es alto Y
    | Homogeneidad es bajo Y Energ a es bajo Y Media es bajo Y
    | Entrop a es alto Y Varianza es bajo
78 | Activaci n media: 0.0231
79 | Magnitud par metros: 4285263.5657
80 | Importancia total: 99075.3106
81 | Bias: 158118.3626
82 | Caracter sticas m s influyentes:
83 | - ASM: 3752640.1873
84 | - Energ a: -1931449.7602
85 | - Homogeneidad: 723843.1133
86 |
87 | --- REGLA #8 ( ndice : 71) ---
88 | Condici n: SI Contraste es alto Y ASM es bajo Y
    | Homogeneidad es bajo Y Energ a es bajo Y Media es alto Y
    | Entrop a es alto Y Varianza es alto
89 | Activaci n media: 0.0347
```

```

90 Magnitud par metros: 2556219.2586
91 Importancia total: 88765.3939
92 Bias: -1596066.3536
93 Caracter sticas m s influyentes:
94   - ASM: 1806176.0031
95   - Energ a: 849623.9137
96   - Entrop a: 47275.4014
97
98 --- REGLA #9 ( ndice : 119) ---
99 Condici n: SI Contraste es alto Y ASM es alto Y
    Homogeneidad es alto Y Energ a es bajo Y Media es alto Y
    Entrop a es alto Y Varianza es alto
100 Activaci n media: 0.0793
101 Magnitud par metros: 1057185.6478
102 Importancia total: 83819.5958
103 Bias: -411950.1575
104 Caracter sticas m s influyentes:
105   - ASM: -893811.2485
106   - Energ a: 366531.2591
107   - Homogeneidad: 121138.3472
108
109 --- REGLA #10 ( ndice : 39) ---
110 Condici n: SI Contraste es bajo Y ASM es alto Y
    Homogeneidad es bajo Y Energ a es bajo Y Media es alto Y
    Entrop a es alto Y Varianza es alto
111 Activaci n media: 0.0215
112 Magnitud par metros: 3449888.4011
113 Importancia total: 74137.3909
114 Bias: -435716.2392
115 Caracter sticas m s influyentes:
116   - ASM: -3365391.6904
117   - Energ a: 615031.8234
118   - Entrop a: 78131.8161

```

Listing A.1: Reporte reglas